Aprendizagem

Instituto Superior Técnico

setembro de 2023

Homework 2 - Report

Joana Pimenta (103730), Rodrigo Laia (102674)

Pen and Paper

1. (a) y_1, y_2, y_3, y_4 and y_5 independent $\implies p(y_1, y_2, y_3, y_4, y_5) = p(y_1, y_2) \times p(y_3, y_4) \times p(y_5)$

Fórmulas utilizadas:

$$P(y_6 = H|\vec{x}) = \frac{P(\vec{x}|y_6 = H)}{P(\vec{x})} \tag{1}$$

$$P(\vec{x}|\mu, \sigma^2) = \frac{1}{(2\pi)^{m/2}\sqrt{|\Sigma|}} e^{-\frac{1}{2}(\vec{x}-\vec{\mu})^T \cdot \Sigma^{-1} \cdot (\vec{x}-\vec{\mu})} \tag{2}$$

$$\vec{\mu} = \begin{bmatrix} E(y_1) \\ E(y_2) \end{bmatrix} \tag{3}$$

$$cov(x, y) = \sum_{i=1}^{n} \frac{(x_i - E(x))(y_i - E(y))}{n} \tag{4}$$

$$\Sigma = \begin{bmatrix} cov(y_1, y_2) & cov(y_1, y_1) \\ cov(y_2, y_1) & cov(y_2, y_2) \end{bmatrix} \tag{5}$$

$$|\Sigma| = cov(y_1, y_2) \cdot cov(y_2, y_1) - cov(y_1, y_1) \cdot cov(y_2, y_2) \tag{6}$$

$$\Sigma^{-1} = \frac{1}{|\Sigma|} \cdot \begin{bmatrix} cov(y_2, y_2) & -cov(y_1, y_2) \\ -cov(y_2, y_1) & cov(y_1, y_1) \end{bmatrix} \tag{7}$$

Parâmetros das gaussianas multivariadas:

Classe A:

$$\vec{\mu}_A = \begin{bmatrix} 0.24 \\ 0.52 \end{bmatrix}$$

$$\Sigma_A = \begin{bmatrix} 0.004267 & -0.0064 \\ -0.0064 & 0.02240 \end{bmatrix}$$

$$|\Sigma|_A = 5.4613 \cdot 10^{-5}$$

$$\Sigma_A^{-1} = \begin{bmatrix} 410.1563 & -117.1875 \\ -117.1875 & 78.125 \end{bmatrix}$$

$$P(\vec{x}|A) = N(\vec{x}|\mu_A, \Sigma_A) = \frac{1}{(2\pi)^{m/2}\sqrt{|\Sigma_A|}} e^{-\frac{1}{2}(\vec{x}-\vec{\mu}_A)^T \cdot \Sigma_A^{-1} \cdot (\vec{x}-\vec{\mu}_A)}$$

Classe B:

$$\vec{\mu}_B = \begin{bmatrix} 0.5925 \\ 0.3275 \end{bmatrix}$$

$$\Sigma_B = \begin{bmatrix} 0.01717 & -0.00732 \\ -0.00732 & 0.02362 \end{bmatrix}$$

$$|\Sigma|_B = 3.519 \cdot 10^{-4}$$

$$\Sigma_B^{-1} = \begin{bmatrix} 67.1101 & 20.7954 \\ 20.7954 & 48.7831 \end{bmatrix}$$

$$P(\vec{x}|B) = N(\vec{x}|\mu_B, \Sigma_B) = \frac{1}{(2\pi)^{m/2}\sqrt{|\Sigma_B|}} e^{-\frac{1}{2}(\vec{x}-\vec{\mu}_B)^T \cdot \Sigma_B^{-1} \cdot (\vec{x}-\vec{\mu}_B)}$$

Probabilidades para $\{y_3, y_4\}$ condicionadas a A e B :

Classe A:

	$y_3 = 0$	$y_3 = 1$
$y_4 = 0$	P=0	P=1/3
$y_4 = 1$	P=1/3	P=1/3

Tabela 1: Probabilidades para y_3, y_4 condicionadas a A

Classe B:

	$y_3 = 0$	$y_3 = 1$
$y_4 = 0$	P=1/2	P=1/4
$y_4 = 1$	P=1/4	P=0

Tabela 2: Probabilidades para y_3, y_4 condicionadas a B

Probabilidades para $\{y_5\}$ condicionadas a A e B :

Classe A:

$$P(y_5 = 0|A) = 1/3$$

$$P(y_5 = 1|A) = 1/3$$

$$P(y_5 = 2|A) = 1/3$$

Classe B:

$$P(y_5 = 0|A) = 1/4$$

$$P(y_5 = 1|A) = 1/2$$

$$P(y_5 = 2|A) = 1/4$$

Priors:

$$P(A) = \frac{3}{7}$$

$$P(B) = \frac{4}{7}$$

(b) Uma vez que o denominador é o mesmo para todas para saber qual a classe mais provável, basta comparar os numeradores das probabilidades.

$$\begin{aligned} P(A|\vec{x}_8) &= \frac{P(\vec{x}_8|A) \cdot P(A)}{P(\vec{x}_8)} \\ &= \frac{P(y_1 = 0.38, y_2 = 0.52|A) \cdot P(y_3 = 0, y_4 = 1|A) \cdot P(y_5 = 0|A) \cdot P(A)}{P(\vec{x}_8)} \\ &= \frac{\frac{3}{7} \cdot 0.3868 \cdot \frac{1}{3} \cdot \frac{1}{3}}{P(\vec{x}_8)} \\ &= \frac{0.018}{P(\vec{x}_8)} \end{aligned}$$

$$\begin{aligned} P(B|\vec{x}_8) &= \frac{P(\vec{x}_8|B) \cdot P(B)}{P(\vec{x}_8)} \\ &= \frac{P(y_1 = 0.38, y_2 = 0.52|B) \cdot P(y_3 = 0, y_4 = 1|B) \cdot P(y_5 = 0|B) \cdot P(B)}{P(\vec{x}_8)} \\ &= \frac{\frac{4}{7} \cdot 1.7678 \cdot \frac{1}{4} \cdot \frac{1}{4}}{P(\vec{x}_8)} \\ &= \frac{0.063}{P(\vec{x}_8)} \end{aligned}$$

Como $P(A|\vec{x}_8) < P(B|\vec{x}_8)$, então $\vec{x}_8$ é classificado como B.

$$\begin{aligned} P(A|\vec{x}_9) &= \frac{P(\vec{x}_9|A) \cdot P(A)}{P(\vec{x}_9)} \\ &= \frac{P(y_1 = 0.42, y_2 = 0.59|A) \cdot P(y_3 = 0, y_4 = 1|A) \cdot P(y_5 = 0|A) \cdot P(A)}{P(\vec{x}_9)} \\ &= \frac{\frac{3}{7} \cdot 0.1013 \cdot \frac{1}{3} \cdot \frac{1}{3}}{P(\vec{x}_9)} \\ &= \frac{0.0048}{P(\vec{x}_9)} \end{aligned}$$

$$\begin{aligned} P(B|\vec{x}_8) &= \frac{P(\vec{x}_8|B) \cdot P(B)}{P(\vec{x}_8)} \\ &= \frac{P(y_1 = 0.42, y_2 = 0.59|B) \cdot P(y_3 = 0, y_4 = 1|B) \cdot P(y_5 = 1|B) \cdot P(B)}{P(\vec{x}_8)} \\ &= \frac{\frac{4}{7} \cdot 1.4927 \cdot \frac{1}{4} \cdot \frac{1}{2}}{P(\vec{x}_8)} \\ &= \frac{0.1066}{P(\vec{x}_8)} \end{aligned}$$

Como $P(A|\vec{x}_9) < P(B|\vec{x}_9)$, então $\vec{x}_9$ é classificado como B.

(c) Assumindo o critério de Maximum Likelihood, para classificar uma observação apenas interessam as probabilidades $P(\vec{x}|A)$ e $P(\vec{x}|B)$:

$$h = argmax(P(\vec{x}_8|h))$$

Considerando diferentes thresholds θ para as probabilidades é possível maximizar a accuracy do nosso classificador:

$$f(\vec{x}_8) = \begin{cases} A & \text{se } P(A|\vec{x}_8) > \theta \\ B & \text{otherwise} \end{cases}$$

$$P(\vec{x}_8|A) = P(y_1 = 0.38, y_2 = 0.52|A) \cdot P(y_3 = 0, y_4 = 1|A) \cdot P(y_5 = 0|A) = 0.043$$

$$P(\vec{x}_9|A) = P(y_1 = 0.42, y_2 = 0.59|A) \cdot P(y_3 = 0, y_4 = 1|A) \cdot P(y_5 = 0|A) = 0.0113$$

Assumindo o critério de maximum Likelihood os priors são todos iguais. Escolhendo qualquer valor no intervalo (0.0113,0.043) como threshold θ, a accuracy do classificador é de 100% para estas observações de teste.

2. As fórmulas utilizadas neste exercício são:

$$\hat{z} = \frac{\sum_{i=1}^{k} w_i \cdot z_i}{\sum_{i=1}^{k} w_i}$$

$$MAE = \frac{\frac{1}{n}}{\sum_{i=1}^{n} |z_i - \hat{z}|}$$

Para discretizar a variável y_2, considerando equal-width, é necessário dividir o intervalo $[0, 1]$ em 2 partes iguais. Assim, os intervalos são: $[0, 0.5]$, $[0.5, 1]$.

Para cada observação, y_2 pode assumir os valores 0 ou 1, consoante o intervalo em que se encontra o seu valor.

y_2	0.36	0.48	0.72	0.11	0.39	0.28	0.53	0.52	0.59
y_{2new}	0	0	1	0	0	0	1	1	1

(a) Em 3-Fold cross-validation o dataset é dividido em 3 partes iguais. Duas delas são usadas para teste e uma para treino.

Porque não há shuffling:

Tabela 3: 1º Fold

x_1	0	1	1	0	A
x_2	0	1	0	1	A
x_3	1	0	1	2	A

Tabela 4: 2º Fold

x_1	0	0	0	1	B
x_2	0	0	0	0	B
x_3	0	1	0	2	B

Tabela 5: 3º Fold

x_1	1	0	1	1	B
x_2	1	0	1	0	A
x_3	1	0	1	1	B

(b)

D	y_1	y_2	y_3	y_4	y_5	y_6	
x_1	0.24	0	1	1	0	A	TRAIN
x_2	0.16	0	1	0	1	A	
x_3	0.32	1	0	1	2	A	
x_4	0.54	0	0	0	1	B	
x_5	0.66	0	0	0	0	B	
x_6	0.76	0	1	0	2	B	
x_7	0.41	1	0	1	1	B	TEST
x_8	0.38	1	0	1	0	A	
x_9	0.42	1	0	1	1	B	

Para x_7:

d	x_1	x_2	x_3	x_4	x_5	x_6
x_7	4	4	2	2	3	4

As observações com menor distância de Hamming são x_3, x_4 e x_5. O output previsto pelo kNN é dado por

$$\hat{z}_7 = \frac{1/2 \cdot 0.32 + 1/2 \cdot 0.54 + 1/3 \cdot 0.66}{1/2 + 1/2 + 1/3} = 0.4875$$

Para x_8:

d	x_1	x_2	x_3	x_4	x_5	x_6
x_8	2	4	1	4	3	5

As observações com menor distância de Hamming são x_1, x_3 e x_5. O output previsto pelo kNN é dado por

$$\hat{z}_8 = \frac{1/2 \cdot 0.24 + 1 \cdot 0.32 + 1/3 \cdot 0.66}{1/2 + 1 + 1/3} = 0.36$$

Como as observações x_7 e x_9 são iguais, o output previsto pelo kNN para x_9 é igual ao output previsto para x_7.

$$\hat{z}_9 = \hat{z}_7 = 0.4875$$

Por fim, o MAE deste classificador é dado por:

$$MAE = \frac{1}{3} \cdot (|0.41 - 0.4875| + |0.38 - 0.36| + |0.42 - 0.4875|) = 0.055$$

Programming - Código Python e Resultados Obtidos

1. O objetivo deste exercício é comparar a performance de dois classificadores (Naive Bayes com distribuição Gaussiana e kNN) para o dataset.

   (a) Boxplots para as accuracies obtidas para GaussianNB e kNN:

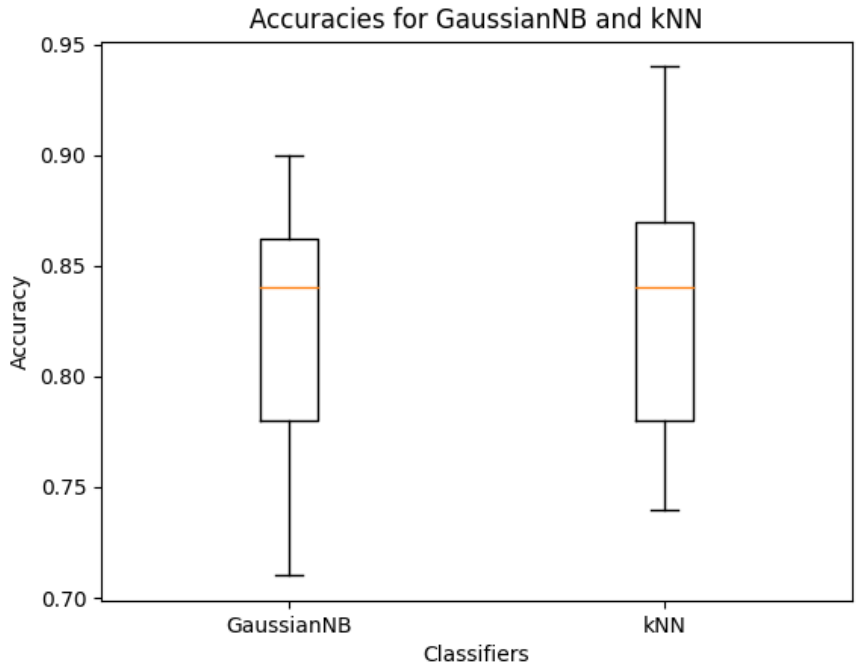

Figura 1: Boxplot para as accuracies obtidas para GaussianNB e kNN

Conclui-se que apesar do o classificador kNN atingir accuracies maiores do que o GaussianNB, a mediana de ambos é quase igual. Além disso, o kNN tem accuracies ligeiramente mais dispersas (a sua distância interquartis é maior). A amplitude do boxplot é parecida para ambos os classificadores.

Código utilizado:

```
### Exercise 1 ###

#a)

acc_folds_gauss = []
acc_folds_knn = []
folds = StratifiedKFold(n_splits=10, shuffle=True, random_state=0)

# Gaussian Naive Bayes
gaussNB = GaussianNB()

# KNN
knn_predictor = KNeighborsClassifier(n_neighbors=5)

# iterate per fold
for train_k, test_k in folds.split(features, target):
    X_train, X_test = features.iloc[train_k], features.iloc[test_k]
```

```
    y_train, y_test = target.iloc[train_k], target.iloc[test_k]

    ## train and assess
    gaussNB.fit(X_train, y_train)
    y_pred_gauss = gaussNB.predict(X_test)
    acc_folds_gauss.append(round(metrics.accuracy_score(y_test,
   y_pred_gauss),2))

    knn_predictor.fit(X_train, y_train)
    y_pred_knn = knn_predictor.predict(X_test)
    acc_folds_knn.append(round(metrics.accuracy_score(y_test,
   y_pred_knn),2))

print("Fold accuracies GaussianNB:", acc_folds_gauss)
print("Fold accuracies kNN:", acc_folds_knn)

plt.boxplot([acc_folds_gauss, acc_folds_knn], labels=['GaussianNB',
    'kNN'])
plt.title('Accuracies for GaussianNB and kNN')
plt.xlabel('Classifiers')
plt.ylabel('Accuracy')
plt.savefig('ex1a_boxplot.png')
plt.show()

```

(b) Concluímos que a hipótese nula (H0: kNN não é estatisticamente superior a GaussianNB) não é rejeitada, uma vez que o p-value é maior do que 0.05, logo kNN não é estatisticamente superior a GaussianNB.

Código utilizado:

```
#b)
Null Hypothesis: kNN is not statistically superior to GaussianNB
hypothesis = stats.ttest_rel(acc_folds_knn, acc_folds_gauss,
   alternative='greater')

if hypothesis[1] < 0.05:
    print("The null hypothesis is rejected and kNN is statistically
    superior to GaussianNB")

else:
    print("The null hypothesis is not rejected and there is no
   statistical superiority between kNN and GaussianNB")

```

2. O objetivo deste exercício é comparar a performance de dois classificadores : kNN com k=1 e kNN com k=5. Assim, calculamos as matrizes de confusão para os dados de cada uma das 10 iterações, somámos os valores de cada célula obtendo duas matrizes de confusão cumulativas que subtraímos uma a outra (kNN com k=1 - kNN com k=5).

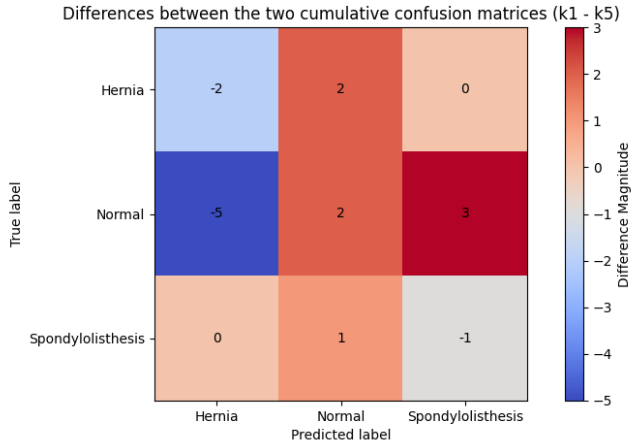

Figura 2: Matriz de confusão cumulativa para kNN com k=1 - kNN com k=5

CONCLUSÕESSSSS FAAAAAFIIIIIII

```
        ############ Exercise 2 ############

        #Initialize the cumulative confusion matrices
        cum_conf_matrix1 = np.zeros((3,3))
        cum_conf_matrix5 = np.zeros((3,3))

        for train_k, test_k in folds.split(features, target):
            X_train, X_test = features.iloc[train_k], features.iloc
    [test_k]
            y_train, y_test = target.iloc[train_k], target.iloc[
    test_k]

            ## train and assess
            knn1 = KNeighborsClassifier(n_neighbors=1,weights='
    uniform',metric='euclidean')
            knn5 = KNeighborsClassifier(n_neighbors=5,weights='
    uniform',metric='euclidean')

            knn1.fit(X_train, y_train)
            knn5.fit(X_train, y_train)

            # Make predictions
            y_pred1 = knn1.predict(X_test)
            y_pred5 = knn5.predict(X_test)

            # Calculate confusion matrices
            conf_matrix1 = confusion_matrix(y_test, y_pred1)
            conf_matrix5 = confusion_matrix(y_test, y_pred5)

            # Calculate cumulative confusion matrices
            cum_conf_matrix1 += conf_matrix1
            cum_conf_matrix5 += conf_matrix5

        #Calculate the difference between the two confusion
    matrices
        conf_matrix_diff = cum_conf_matrix1 - cum_conf_matrix5

        confusion1 = pd.DataFrame(conf_matrix_diff, index=knn1.
```

```
    classes_, columns=['Predicted Hernia', 'Predicted Normal', '
    Predicted Spondylolisthesis'])
34
35          #Plotting
36          plt.figure(figsize=(10, 5))
37          heatmap = plt.imshow(conf_matrix_diff,cmap="coolwarm",
    interpolation='nearest')
38          plt.title('Differences between the two cumulative confusion
     matrices (k1 - k5)')
39          plt.xlabel('Predicted label')
40          plt.xticks([0, 1, 2], ['Hernia', 'Normal', '
    Spondylolisthesis'])
41          plt.yticks([0, 1, 2], ['Hernia', 'Normal', '
    Spondylolisthesis'])
42          plt.ylabel('True label')
43
44          cbar = plt.colorbar(heatmap)
45          cbar.set_label('Difference Magnitude', rotation=90)
46
47          for i in range(conf_matrix_diff.shape[0]):
48              for j in range(conf_matrix_diff.shape[1]):
49                  plt.text(j, i, str(int(conf_matrix_diff[i, j])), ha
    ='center', va='center', color='black')
50          plt.savefig('ex2_cummatrix.png')
51          plt.show()
52
```

3. Apesar de ser uma abordagem fácil e rápida, o Naive Bayes apresenta algumas desvantagens para este dataset. Um problema é, por exemplo, a suposição de que as features têm uma distribuição Gaussiana. Para podermos visualizar a distribuição experimental destes features fizemos um histograma para cada um deles e concluímos que a maioria não tem uma distribuição Gaussiana, especialmente por exemplo a feature *degree_Spondylolisthesis*.

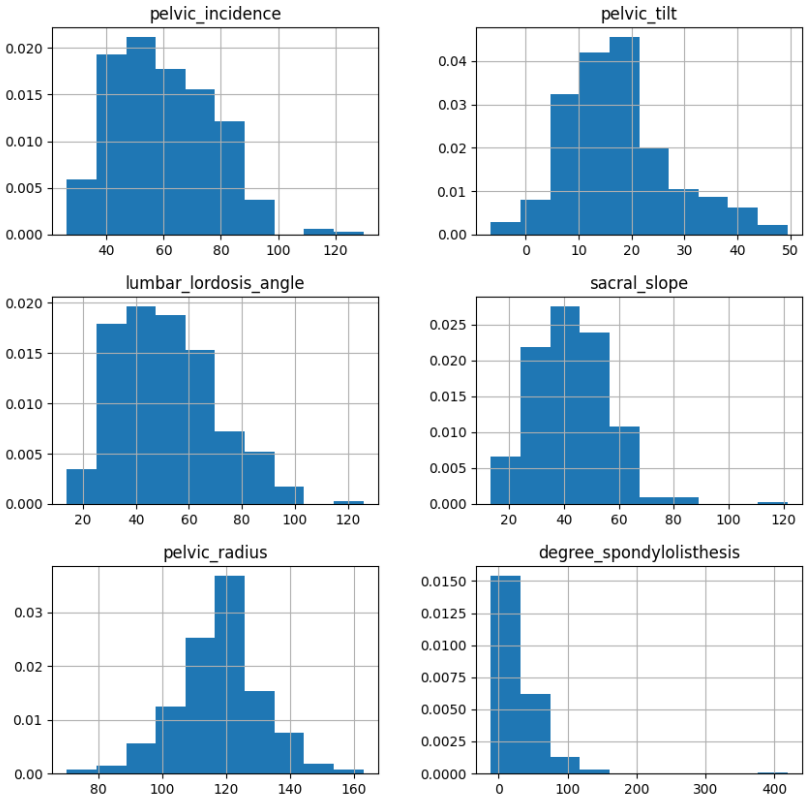

Figura 3: Histogramas para cada feature

Código utilizado:

```
    ############ Exercise 3 ############
    #1. The dataset is not normally distributed, which is an
   assumption of the Naive Bayes classifier.
    #Histograms for each feature:
    features.hist(figsize=(10,10),density=True)
    plt.savefig('ex3_1_hist.png')
    plt.show()
```

Para além disso, outro exemplo de uma dificuldade do Naive Bayes é a suposição de que as features são independentes. Para avaliar se estas featuras eram independentes ou não, fizemos a seguinte matriz de correlação:

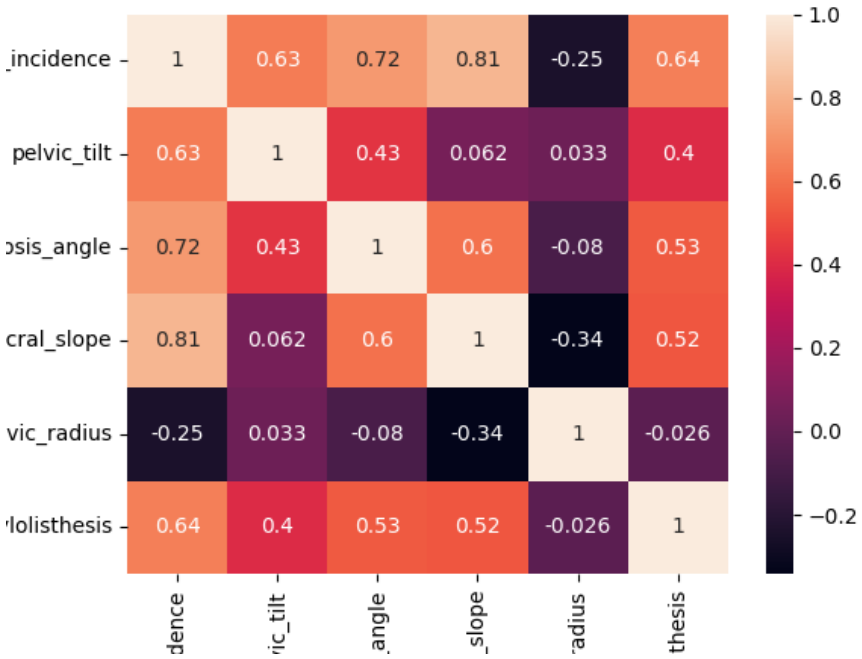

Figura 4: Matriz de correlação

Ao observar a matriz de correlação, concluímos que apesar de algumas features se encontrarem muito pouco correladas, podendo por isso ser aproximadas como independentes (como por exemplo *pelvic_radius* e *pelvic_tilt*), há outras que se encontram bastante correladas e consequentemente não podem ser aproximadas como independentes (como por exemplo *pelvic_incidence* e *sacral_slope*).

Código utilizado: